

Assignment1-Adversarial attacks analysis report

2024480022 홍정민

1. 공격 성공률

Dataset	Attack method	eps=0.05	eps=0.1	eps=0.2	eps=0.3
MNIST	Targeted FGSM	0.2%	2.13%	15.42%	41.18%
	Untargeted FGSM	4.36%	15.01%	61.36%	86.41%
	Targeted PGD	0.2%	6.39%	83.98%	100%
	Untargeted PGD	5.98%	35.5%	98.8%	100%
CIFAR-10	Targeted FGSM	9.19%	8.65%	7.03%	6.49%
	Untargeted FGSM	86.49%	88.11%	90.27%	88.11%
	Targeted PGD	100%	100%	100%	100%
	Untargeted PGD	100%	100%	100%	100%

2. 결과 분석

1) epsilon와 visibility의 tradeoff

MNIST 데이터셋을 보면 epsilon의 값이 커질수록 Targeted FGSM과 Untargeted FGSM 모두 공격 성공률이 상승하는 것을 볼 수 있다. 이는 모델을 속이기 위하여 픽셀 값을 크게 조작할수록 모델이 틀린 값을 내기 때문이다. 그러나, 시각화된 이미지에서 결과를 확인해 봤을 때, epsilon이 0.3처럼 큰 값을 사용하면 노이즈가 사람의 눈에도 뚜렷하게 보이는 것을 확인할 수 있다. 이는 imperceptible 규칙을 위반하는 경우이다. 이를 통해, epsilon이 커지면 공격 성공률이 증가하지만, 동시에 사람의 눈에 들킬 확률도 같이 높아지는 트레이드오프 관계가 존재함을 수치적으로 확인했다.

2) FGSM vs PGD

동일한 epsilon에서 비교했을 때, 반복적인 최적화 과정을 거치는 PGD의 공격 성공률이 FGSM보다 높은 것을 확인할 수 있다. FGSM은 손실 함수의 기울기 방향으로 한번 크게 점프하기 때문에 최적의 지점을 지나치거나 도달하지 못할 수 있다. 반면에 PGD는 작은 step으로 여러 번 반복 이동하기 때문에 화이트박스 환경에서 훨씬 위협적으로 공격할 수 있다.

3) Targeted vs Untargeted

MNIST와 CIFAR-10 두 개 모두의 데이터셋을 봤을 때, untargeted attack이 targeted attack보다 높은 공격 성공률을 보였다. 이는 untargeted attack은 정답 클래스의 decision boundary 밖으로만 이미지를 밀어내면 성공한 공격이지만, targeted attack은 특정 오답 클래스로 정확히 맞춰야하기 때문에 최적화 난이도가 훨씬 높기 때문으로 분석할 수 있다.

4) 예상치 못한 결과

- CIFAR-10의 Targeted FGSM의 공격성공률이 epsilon이 커질수록 줄어드는 이유
FGSM은 모델의 decision boundary가 선형일 것이라고 가정하고 노이즈를 만든다. Targeted attack은 특정 클래스로 정확히 이미지가 안착해야 한다. epsilon이 크면 올바른 오답 클래스로 향하기하지만 지나쳐 다른 클래스로 추정해버린다. 이 때문에 epsilon이 커질수록 공격 성공률이 떨어지는 결과를 보인다.

- 전체적인 공격성공률이 MNIST보다 CIFAR-10이 높은 이유
CIFAR-10이 더 복잡한 데이터이기 때문에 모델을 속이기 더 어려울 것이라고 생각했지만 이와 반대되는 결과를 볼 수 있다. 데이터셋의 차원 크기의 차이 때문에 같은 크기의 노이즈를 주어도 CIFAR-10에서 MNIST보다 4배 이상의 오차를 만들어낸다. 또한, CIFAR-10의 decision boundary가 MNIST보다 훨씬 울퉁불퉁하여 살짝의 노이즈를 주어도 쉽게 오분류가 난다. 이러한 이유로 인해 복잡한 데이터가 간단한 데이터보다 공격 성공률이 높다는 것을 확인할 수 있다.